

PROJETO 3_ RISCO RELATIVO

Progress	0%
Status	Done
Team	

Maria Eduarda Carvalho de Castro_ Jornada de Dados Laboratória J01_ 2025.

Contexto e Objetivos:
Com o aumento da demanda por crédito e o processo manual sobrecarregado, o banco Super Caja busca automatizar a análise de solicitações para ganhar eficiência e agilidade.

- O objetivo principal é reduzir o risco de inadimplência, identificando com mais precisão os clientes de maior risco.

O meu projeto propõe formas de construir os melhores parâmetros para esse novo sistema, avaliando quais características mais contribuem para a inadimplência e como combiná-las em uma pontuação de risco confiável.

Linguagens e Ferramentas:

- SQL + Bigquery_ tratamento da base dados.
- Python + GoogleColab_ análise exploratória, testes estatísticos e criação de gráficos.
- Looker Studio_ visualização e criação do dashboard.
- Notion_ acompanhamento do processo.

Links Úteis:
https://colab.research.google.com/drive/1Yx-ip8KkN9QLWg-nfWph80RyN7PJzWO3?usp=sharing / **Vídeo do Processo** / **Análise**

Exploratória Looker / Dashboard Interativa

▼ MARCO 01: PROCESSAMENTO E PREPARO DA BASE

1. **CONECTAR DADOS + IDENTIFICAR E TRATAR VALORES NULOS + IDENTIFICAR E TRATAR VALORES DUPLICADOS:**

Arquivo	Variável	Descrição	Tipo Original	Nulos	Duplicados
`user_info`	`user id`	Número de identificação do cliente (único para cada cliente)	INTEGER	0	-
36000 linhas	`age`	Idade do cliente	INTEGER	0	-
	`sex`	Gênero do cliente	STRING	0	-
	`last month salary`	Último salário mensal que o cliente informou ao banco	FLOAT	**7199**	-
	`number dependents`	Número de dependentes	INTEGER	943	-
`loans_outstanding` /emprestimos	`loan id`	Número de identificação do empréstimo (único para cada empréstimo)	INTEGER	0	0
305335 linhas	`user id`	Número de identificação do cliente	INTEGER	0	34510 user_id com +1 empréstimos
	`loan type`	Tipo de empréstimo (real state = imóveis, others = outros)	STRING	0	-
`loans_detail` /infopagamento	`user id`	Número de identificação	INTEGER	0	-

Arquivo	Variável	Descrição	Tipo Original	Nulos	Duplicados
		do cliente			
36000 linhas	`more 90 days overdue`	Número de vezes que o cliente apresentou atraso superior a 90 dias	INTEGER	0	-
	`using lines not secured personal assets`	Quanto o cliente está utilizando em relação ao seu limite de crédito, em linhas que não são garantidas por bens pessoais, como imóveis e automóveis	FLOAT	0	-
	`number times delayed payment loan 30 59 days`	Número de vezes que o cliente atrasou o pagamento de um empréstimo (entre 30 e 59 dias)	INTEGER	0	-
	`debt ratio`	Relação entre dívidas e ativos do cliente. Taxa de endividamento = Dívidas / Patrimônio	FLOAT	0	-
	`number times delayed payment loan 60 89 days`	Número de vezes que o cliente atrasou o pagamento de um empréstimo (entre 60 e 89 dias)	INTEGER	0	-
`default` /flag	`user id`	Número de identificação do cliente	INTEGER	0	

Arquivo	Variável	Descrição	Tipo Original	Nulos	Duplicados
36000 linhas	`default flag`	Classificação dos clientes inadimplentes (1 para clientes já registrados alguma vez como inadimplentes, 0 para clientes sem histórico de inadimplência)	INTEGER	0	

▼ CÓDIGOS DAS CONSULTAS

```
SELECT
COUNTIF (user_id IS NULL) AS id_nulo,
COUNTIF(age IS NULL) AS idade_nula,
COUNTIF (sex IS NULL) AS sexo_nulo,
COUNTIF(last_month_salary IS NULL) AS salario_nulo,
COUNTIF(number_dependents IS NULL) AS dependentes_nulos,
 FROM `projetolab3.bancocaja.user_info`
```

Conferência de Nulos

```
SELECT
  user_id,
  age,
  sex,
  COALESCE(last_month_salary, 0.0) AS salario,
  COALESCE(number_dependents, 0) AS dependentes
FROM `projetolab3.bancocaja.user_info`;
```

“view_user_info_limpo”

```
SELECT
  user_id,
  COUNT(*) AS qtd_repeticoes
 FROM `projetolab3.bancocaja.user_info`
  GROUP BY user_id
  HAVING COUNT (*) > 1
  ORDER BY qtd_repeticoes DESC;
```

Conferência de Duplicado

🚧 **LEMBRET**
criar na tabela resumo: coluna de empréstim

```sql
SELECT
COUNTIF(user_id IS NULL) AS id_nulo,
COUNTIF(loan_id IS NULL) AS loan_nulo,
COUNTIF(loan_type IS NULL) AS type_nulo,
 FROM `projetolab3.bancocaja.emprestimos`;
```

Conferência de Nulos

```sql
--- conferir se tem loan_id duplicado:
SELECT
  loan_id,
  COUNT (*) AS qtd_repeticoes
 FROM `projetolab3.bancocaja.emprestimos`
  GROUP BY loan_id
  HAVING COUNT (*) > 1
  ORDER BY qtd_repeticoes DESC;

  --- conferir usuários com +1 emprestimo:
  SELECT
  user_id,
  COUNT (*) AS qtd_repeticoes
 FROM `projetolab3.bancocaja.emprestimos`
  GROUP BY user_id
  HAVING COUNT (*) > 1
  ORDER BY qtd_repeticoes DESC;
```

Conferência de Duplicado

(qtd de
emprestim
por usuari
tipo_empr
(tipo de
emprestim
preferido
usuario/m
recorrente

```sql
SELECT
  COUNTIF (user_id IS NULL) AS user_nulo,
  COUNTIF (default_flag IS NULL) AS flag_nulo,
FROM `projetolab3.bancocaja.flag` ;
```

Conferência de Nulos

```sql
SELECT
  COUNTIF(user_id IS NULL) AS id_nulo,
    COUNTIF(more_90_days_overdue IS NULL) AS more_nulo,
    COUNTIF(using_lines_not_secured_personal_assets IS NULL) AS lines_nulo,
    COUNTIF(number_times_delayed_payment_loan_30_59_days IS NULL) AS delayed_nulo,
    COUNTIF(debt_ratio IS NULL) AS ratio_nulo,
    COUNTIF(number_times_delayed_payment_loan_60_89_days IS NULL) AS dalayed_2_nulo,
 FROM `projetolab3.bancocaja.infopagamento` ;
```

Conferência de Nulos

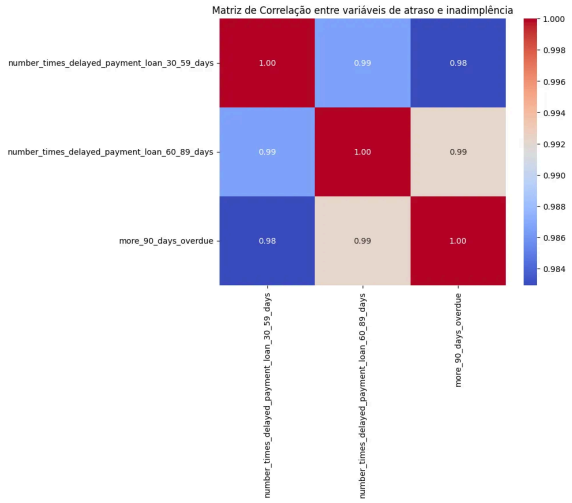
📎DECISÃO:

- Transformar nulos de `last month salary` em ‘0’;
- Transformar nulos de `number dependents` em ‘0’;

---

2. **IDENTIFICAR E GERENCIAR DADOS FORA DO ESCOPO DA ANÁLISE**

Este passo foi feito no https://colab.research.google.com/drive/1Yx-ip8KkN9QLWg-nfWph80RyN7PJzWO3?usp=sharing onde gerei um Mapa de Calor que comparava a correlação entre todas as variáveis numéricas:



- Todas as variáveis de dias de atraso no pagamento se destacam - com isso foi para o desvio padrão;
    - Comparando o desvio padrão entre as 3 variáveis:

```
Desvio padrão das variáveis analisadas:
number_times_delayed_payment_loan_30_59_days    4.14
number_times_delayed_payment_loan_60_89_days    4.11
more_90_days_overdue                            4.12
dtype: Float64
```

**Conferir códigos da consulta no GoogleColab.*

📎DECISÃO:
Manter a variável `number times delayed payment loan 30 59 days` que apresentou o maior desvio padrão de **4.14.**

---

3. **IDENTIFICAR E TRATAR DADOS INCONSISTENTES EM VARIÁVEIS CATEGÓRICAS**

Conferi os tipos diferentes:

```
SELECT
DISTINCT sex
 FROM `projetolab3.bancocaja.user_info`
```

Não apresentou dados discrepantes.

```
SELECT
DISTINCT loan_type
 FROM `projetolab3.bancocaja.emprestimos`
```

Apresentou dados discrepantes.

Criei view limpa para empréstimos:

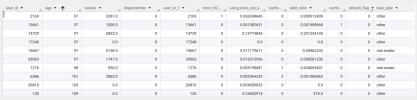
```
SELECT
loan_id,
user_id,
CASE
  WHEN LOWER(loan_type) IN ('other','others','OTHER','Other') THEN 'other'
  WHEN LOWER(loan_type) IN ('real estate','REAL ESTATE','Real Estate') THE
N 'real estate'
  END AS tipo_padronizado
  FROM `bancocaja.emprestimos`;
```

---

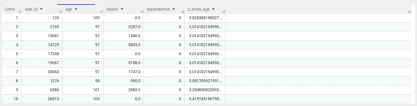
4. **IDENTIFICAR E TRATAR DADOS DISCREPANTES EM VARIÁVEIS NUMÉRICAS**

> **user_info:** Aplicação de IQR + ZScore com SQL no BigQuery.

💬 **RESULTADOS DE AGE:**



Discrepantes de age com IQR - 10 resultados.



Discrepantes de age com Z SCORE - 10 resultados.

📎 **DECISÃO AGE:**
Manter todos.

- Eles **não têm salário nulo em todos os casos**;
- Estão **sem dependentes**, o que faz sentido pra idade avançada;
- Têm comportamento típico de quem **poderia mesmo existir no banco**.
- Eles são **outliers reais** — representam **casos raros**, mas possíveis.
- **Não são erros de preenchimento.**

💬 **RESULTADOS DE SALÁRIO:**

IQR_ indica 1.021 discrepantes, salários > 16.332,50

Z SCORE_ indica 102 discrepantes, salários > 41.666,00

📎 **DECISÃO SALÁRIO:**
Manter todos.

- **Não há indícios de erro de preenchimento** entre

💬 **RESULTADOS DE DEPENDENTES:**

IQR_ indica 3.230 **discrepantes**, sendo que 2.325 deles são “3”, o que eu considero um nicho e não outliers.

Z SCORE_ indica 236 **discrepantes**, a partir de 5 dependentes.

os outliers — todos os valores são plausíveis.

- **Outliers pelo IQR (> R$ 16.332,50)**: representam clientes que ganham acima da média, mas ainda dentro de padrões realistas.
- **Outliers pelo Z-score (> R$ 41.666,00)**: identificam a **elite da base**, com alto poder aquisitivo.
- **Nenhum cliente com Z-score > 3** apresentou inadimplência (`default_flag = 1`), o que indica **risco relativo próximo de zero** para esse grupo.

📎 **DECISÃO DEPENDENTES: Manter todos.**

- Tratar os casos com 7+ dependentes como **casos raros, mas reais**
- Observar se existe relação indireta com outras variáveis (ex: renda, tipo de empréstimo) nas próximas análises

> **info_pagamentos:** Aplicação de IQR + ZScore com Python no https://colab.research.google.com/drive/1Yx-ip8KkN9QLWg-nfWph80RyN7PJzWO3?usp=sharing .

💬 **RESULTADOS DE `debt_ratio`:**

Item	Detalhamento
Descrição da variável	Relação entre dívidas e renda mensal do cliente.
Faixa principal de valores	Maioria dos valores até 1.5.
Limite superior (IQR)	1.92
Outliers identificados (IQR)	7.579 registros
Descoberta crítica	Dos 7.579 outliers, 7.262 têm salário ≤ 1
Critério de inconsistência	`salario <= 482.05 AND debt_ratio > 1.92 THEN 'salário inconsistente' salario >=482.05 AND debt_ratio > 1.92 THEN 'debt ratio inconsistente'`
Número de registros inconsistentes	7.579 registros (total pelo iqr) 7.305 (`<= 482.05`) 274 (`>=482.05`)
Referência adotada para salário mínimo válido	R$ 482,05 (valor da bolsa de estágio formal - gov.br)
Ação tomada	Isolar casos com uma flag e manter.

📎 **DECISÃO `debt_ratio`:**
Foram criadas as flags:

1. `debt_categoria`: caracteriza o nível de "saúde" do valor de `debt_ratio` do cliente.

```
 CASE
    WHEN debt_ratio <=1 T
HEN "saudável"
    WHEN debt_ratio BETWE
EN 1.01 AND 2.0 THEN "ate
nção"
    WHEN debt_ratio BETWE
EN 2.01 AND 5.0 THEN "ris
co relevante"
    WHEN debt_ratio BETWE
EN 5.01 AND 10 THEN "altí
ssimo risco"
    WHEN debt_ratio >10 T
HEN "caso extremo"
END AS debt_categoria
```

2. `debt_status` : sinaliza se aquele cliente possui um `debt_ratio` discrepante por ter um salário inconsistente ou não. No caso de 'valores consistentes' são clientes que não se encontram dentro dos valores discrepantes.

```
CASE
    WHEN salario <= 482.0
5 AND debt_ratio > 1.92 T
HEN 'salário inconsistent
e'
    WHEN salario >=482.05
AND debt_ratio > 1.92 THE
N 'debt ratio inconsisten
te'
  ELSE 'valores consisten
```

```
tes'
END AS debt_status
```

💬 **RESULTADOS DE `using lines not secured personal assets`:**

Item	Detalhamento
Descrição da variável	Proporção do limite de crédito **não garantido** (como cartão ou empréstimo pessoal) que está sendo utilizada pelo cliente.
Distribuição geral	A maioria dos valores está concentrada entre **0.0 e 0.6**. Valores acima de 1.0 representam uso acima do limite.
Limite IQR (Q3 + 1.5×IQR)	**1.33**
Outliers (IQR)	**177 registros** acima de 1.33
Outliers (Z-score > 3)	**43 registros**
Máximo encontrado	**22.000**
Tratamento aplicado	Criar flag `lines_categoria` **

**Durante a análise de outliers da variável `using_lines_not_secured_personal_assets`, observei valores extremamente altos, como 22.000, o que gerou suspeitas sobre possíveis erros ou distorções. Pa investigar, estimei o valor total da dívid

📎 **DECISÃO `debt_ratio`:**

1. Foi criada a flag `lines_categoria` caracterizando o nível de atenção que devemos ter com os números discrepantes.

```
CASE
    WHEN using_lines_not_
secured_personal_assets B
ETWEEN 1.33 AND 10 THEN
'atenção'
    WHEN using_lines_not_
secured_personal_assets B
ETWEEN 10 AND 100 THEN 'r
isco médio'
    WHEN using_lines_not_
secured_personal_assets B
ETWEEN 100 AND 1000 THEN
'risco alto'
    WHEN using_lines_not_
secured_personal_assets B
ETWEEN 1000 AND 10000 THE
N 'discrepantes'
    WHEN using_lines_not_
secured_personal_assets >
10000 THEN 'extremos'
    ELSE 'saudável'
  END AS lines_categoria,
```

com base no salário e no debt_ratio, tentando assim deduzir o limite de créd utilizado por cada cliente. No entanto, identifiquei diversos casos com salário igual a zero, o que inviabiliza os cálculo e indica inconsistência nos dados. Alér disso, percebi que os clientes com valores extremos de using_lines tambér apresentavam múltiplos empréstimos, que reforça a hipótese de que essa variável representa não apenas o uso d cartão de crédito, mas também outras formas de crédito rotativo. Como havia muitas hipóteses e pouca certeza reso apenas usar a flag para tratar isso mais na frente.

5. **CRIAR NOVAS VARIÁVEIS + UNIR TABELAS + CONSTRUIR TABELAS AUXILIARES**

▼ CÓDIGO DA TABELA CHAVE_`caja_unificada`

```
WITH user_info_tratada AS (
SELECT
  user_id,
  age AS idade,
  CASE
      WHEN age < 18 THEN 'menor de idade'
      WHEN age BETWEEN 18 AND 25 THEN '18-25'
      WHEN age BETWEEN 26 AND 40 THEN '31-40'
      WHEN age BETWEEN 41 AND 50 THEN '41-50'
      WHEN age BETWEEN 51 AND 65 THEN '51-65'
      ELSE '+65'
  END AS faixa_etaria,
CASE
  WHEN dependentes > 0 THEN "sim"
  ELSE "não"
END AS tem_dependentes,
  IFNULL (dependentes, -1) AS n_dependentes,
  IFNULL (salario, 0) AS salario,
  salario / (dependentes +1) AS renda_per_capita,
FROM `bancocaja.view_user_info_limpo`
),
```

```sql
--- RESUMO EMPRESTIMOS:
-- RESUMO DA QUANTIDADE TOTAL DE EMPRÉSTIMOS POR USER
qtd_emprestimos AS (
  SELECT
    user_id,
    COUNT(*) AS qtd_emprestimos,
  FROM `bancocaja.view_emprestimos_limpos`
  GROUP BY user_id
),

-- TIPO MAIS FREQUENTE POR USER_ID
tipo_emprestimo_frequente AS (
  SELECT
    user_id,
    tipo_padronizado,
    ROW_NUMBER() OVER (PARTITION BY user_id ORDER BY COUNT(*) DESC) AS
ordem
  FROM `bancocaja.view_emprestimos_limpos`
  GROUP BY user_id, tipo_padronizado
),

-- FILTRA SÓ O MAIS FREQUENTE DE CADA USER
mais_frequente AS (
  SELECT user_id, tipo_padronizado AS tipo_frequente
  FROM tipo_emprestimo_frequente
  WHERE ordem = 1
),

--- INFORMAÇÕES DE PAGAMENTO:
info_pagamento AS (
SELECT
  user_id,
  using_lines_not_secured_personal_assets,
  number_times_delayed_payment_loan_30_59_days,
  debt_ratio,
CASE
    WHEN debt_ratio <=1 THEN "saudável"
    WHEN debt_ratio BETWEEN 1.01 AND 2.0 THEN "atenção"
    WHEN debt_ratio BETWEEN 2.01 AND 5.0 THEN "risco relevante"
    WHEN debt_ratio BETWEEN 5.01 AND 10 THEN "altíssimo risco"
    WHEN debt_ratio >10 THEN "caso extremo"
END AS debt_categoria
  FROM `bancocaja.view_infopagamento_limpo`
)
```

```sql
SELECT
  u.*,
CASE
  WHEN salario =0 THEN 'sem salário'
  WHEN salario BETWEEN 0 AND 482.05 THEN 'valor infimo'
  ELSE 'possui salário'
END AS salario_status,
  IFNULL (e.qtd_emprestimos, 0) AS qtd_emprestimos,
  IFNULL (f.tipo_frequente, "sem emprestimo") AS tipo_frequente,
  g.default_flag,
  p.using_lines_not_secured_personal_assets,
  CASE
    WHEN using_lines_not_secured_personal_assets BETWEEN 1.33 AND 10 TH
EN 'atenção'
    WHEN using_lines_not_secured_personal_assets BETWEEN 10 AND 100 THE
N 'risco médio'
    WHEN using_lines_not_secured_personal_assets BETWEEN 100 AND 1000 T
HEN 'risco alto'
    WHEN using_lines_not_secured_personal_assets BETWEEN 1000 AND 10000
THEN 'discrepantes'
    WHEN using_lines_not_secured_personal_assets >10000 THEN 'extremos'
    ELSE 'saudável'
  END AS lines_categoria,
  p.number_times_delayed_payment_loan_30_59_days,
  p.debt_ratio,
  p.debt_categoria,
  CASE
    WHEN salario <= 482.05 AND debt_ratio > 1.92 THEN 'salário inconsis
tente'
    WHEN salario >=482.05 AND debt_ratio > 1.92 THEN 'debt ratio incons
istente'
  ELSE 'valores consistentes'
END AS debt_status
FROM user_info_tratada u
LEFT JOIN qtd_emprestimos e ON u.user_id = e.user_id
LEFT JOIN mais_frequente f ON u.user_id = f.user_id
LEFT JOIN info_pagamento p ON u.user_id = p.user_id
LEFT JOIN projetolab3.bancocaja.flag g ON u.user_id = g.user_id
```

📎 TABELA CHAVE_ `caja_unificada`:

variável	tipo	descrição
`user_id`	original	número de identificação do cliente (único para cada cliente)
`age`	original	idade do cliente
`faixa_etaria`	**criada**	faixa etaria em que o cliente se enquadra - utilizei a base do 'score brasil' https://www.serasa.com.br/score/blog/media-score-serasa-conheca-mapa-score/
`tem_dependentes`	**criada**	indica se o cliente tem dependentes
`n_dependentes`	original	quantos dependentes o cliente tem
`salario`	original	último salário mensal que o cliente informou ao banco
`renda_per_capita`	**criada**	quanto **de dinheiro existe para cada dependente**, assumindo que o salário da pessoa sustenta todo mundo (inclusive ela mesma)
`qtd_emprestimos`	**criada**	quantos emprestimos o cliente possui com o banco
`tipo_emprestimo`	**criada**	qual o tipo de emprestimo mais frequente do cliente
`using lines not secured personal assets`	original	quanto o cliente está utilizando em relação ao seu limite de crédito, em linhas que não são garantidas por bens pessoais, como imóveis e automóveis
`number times delayed payment loan 30 59 days`	original	Número de vezes que o cliente atrasou o pagamento de um empréstimo (entre 30 e 59 dias)
`debt_ratio`	original	Relação entre dívidas e ativos do cliente. Taxa de endividamento = Dívidas / Patrimônio
`debt_category`	**criada**	segmentação por conta de outliers
`default_flag`	original	classificação dos clientes inadimplentes (1 para clientes já registrados alguma vez como inadimplentes, 0 para clientes sem histórico de inadimplência)

▼ MARCO 02: ANÁLISE EXPLORATÓRIA

♦ **A PARTIR DAQUI JÁ COMECEI A COMPARAR A BASE ORIGINAL (36.000 linhas) COM A BASE SEM ALGUMAS FLAGS (28.686 linhas):**
A **base sem extremos** foi obtida ao **excluir os registros com os seguintes rótulos**:

- `debt_categoria = 'caso extremo'` → valores de `debt_ratio` muito acima do esperado: `WHEN debt_ratio >10 THEN "caso extremo"`
- `lines_categoria IN ('discrepantes', 'extremos')` → valores exageradamente altos em `using_lines`:

```
 WHEN using_lines_not_secured_personal_assets BETWEEN 1000 AND 10000 THEN 'discrepantes'
WHEN using_lines_not_secured_personal_assets >10000 THEN 'extremos'
```

- `debt_status = 'debt_ratio_inconsistente'` → `WHEN salario >=482.05 AND debt_ratio > 1.92 THEN 'debt ratio inconsistente'`

1. **AGRUPAR DADOS DE ACORDO COM VARIÁVEIS CATEGÓRICAS + VER VARIÁVEIS CATEGÓRICAS**

https://drive.google.com/file/d/12ki1noxbZsZFDDh88c7LH8WtPFSVI-xD/view?usp=sharing

Os gráficos são da base com extremos.

💬 **RESULTADOS / INSIGHTS:**

Já começamos a perceber algumas questões da base:

`faixa_etaria`

- A faixa de **31 a 40 anos** concentra a maior quantidade absoluta de inadimplentes.
- A faixa **18-25 anos** apresenta uma das **maiores proporções relativas** de inadimplência (acima de 3%).
- As faixas mais velhas (+65 e 51-65) têm percentuais menores, indicando menor risco.

`tem_dependentes`

- A presença de dependentes **aumenta discretamente a taxa de inadimplência** (de 1,59% para 2,38% na base com extremos).
- Mesmo sem impacto drástico, pode ser considerada uma variável de apoio.

`debt_categoria`

- Embora os grupos "atenção" e "risco relevante" tenham inadimplência acima da média, a maior parte dos inadimplentes está no grupo "saudável", que possui mais clientes.

`salario_status`

- A maioria dos inadimplentes **tem salário declarado**, então **não ter salário não é o principal fator de risco**.
- Já na base sem extremos, a taxa de inadimplência entre quem **não tem salário** (2,31%) é discretamente maior que a média.

`tipo_emprestimo_frequente`

- Quem **não tem empréstimos registrados** apresenta uma **inadimplência altíssima** (acima de 12%), o que pode indicar inconsistência ou perfil de risco invisível ao sistema.
- Empréstimos do tipo "real estate" têm a maior taxa entre os tipos definidos, sugerindo que o tipo também influencia o risco.

`salario_categoria`

- A maior taxa de inadimplência está entre os que ganham **até 3 salários mínimos**, especialmente **até 1 salário**.
- Acima de 10 salários, as taxas são muito baixas (menores que 1%), com **zero inadimplência** para quem ganha mais de 20 salários.

2. **APLICAR MEDIDAS DE TENDÊNCIA CENTRAL (MODA, MÉDIA, MEDIANA) + VER DISTRIBUIÇÃO**

salário

média	mediana	desvio padrão	maior valor
R$ 5.340,23	R$ 4.369	11.896,99	1.560.100

1 - 1 / 1

renda per capita

média	mediana	desvio pa...	valor max.
3.578,4	2.583	6.693,47	730.483

1 - 1 / 1

emprestimos

média	mediana	desvio pa...	maior valor
8,48	8	5,18	57

1 - 1 / 1

atraso no pagamento

média	mediana	desv. padrão	valor max.
0,42	0	4,14	98

1 - 1 / 1

uso de linha de crédito

média	mediana	desvio pa...	maior valor
5,81	0,15	209.053,44	22.000

1 - 1 / 1

dependentes

média	mediana	desv. padrão	valor max.
0,74	0	1,11	13

1 - 1 / 1

idade

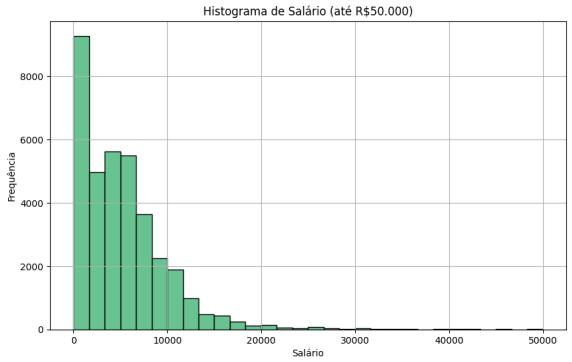
idade	idade	idade	idade
52,42	52	14,79	109

1 - 1 / 1

debt_ratio

média	mediana	desv. padrão	valor max.
351,58	0,37	2.011,64	307.001

1 - 1 / 1



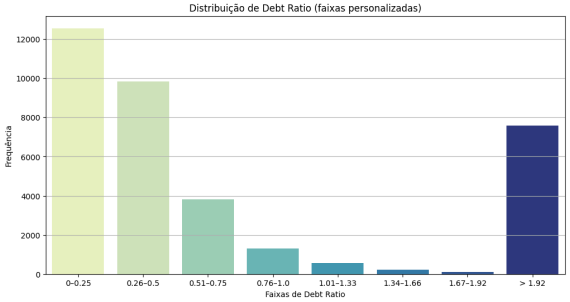
💬 **RESULTADOS / INSIGHTS:**

Algumas variáveis se destacaram na alta dispersão:

- `salário`
  - Média: R$ 5.340 | Desvio padrão: R$ 11.086
  - Histograma com a maioria dos valores à esquerda → muitos clientes com salário baixo e poucos com salários muito altos.
- `debt_ratio`
  - Média: 351.58 | Desvio padrão: 2.011
  - Valor máximo altíssimo: 307.001
  - Gráfico mostra que grande parte dos clientes tem `debt_ratio` até 0.50, mas há uma cauda com valores extremos acima de 1.92 (valor do IQR).
- `using_lines_not_secured_personal_assets`
  - Média: 5.81 | Desvio padrão: 209 | Máximo: 22.000
  - Gráfico confirma: maioria está até 1.33 (valor do IQR), mas existe uma cauda longa que puxa a média para cima.

- `idade`: média e mediana em 52, com desvio padrão mais controlado.
- `dependentes`, `renda per capita`, `atrasos`, `qtd_emprestimos` também têm dispersão mais coerente com o contexto — e não exigem tanta atenção neste momento ou flags.

∗Gráficos feitos no Colab.





3. **CALCULAR QUARTIS + CALCULAR CORRELAÇÃO** *∗Feito com a base com os extremos.*

▼ CÓDIGO DE CRIAÇÃO DOS QUARTIS

```
WITH base AS (
  SELECT
    user_id,
    default_flag,
    -- Variáveis numéricas
    debt_ratio,
    idade,
    n_dependentes,
    number_times_delayed_payment_loan_30_59_days,
    qtd_emprestimos,
    renda_per_capita,
    salario,
    using_lines_not_secured_personal_assets,

    -- Quartis
    NTILE(4) OVER (ORDER BY debt_ratio) AS quartil_debt_ratio,
    NTILE(4) OVER (ORDER BY idade) AS quartil_idade,
    NTILE(4) OVER (ORDER BY n_dependentes) AS quartil_dependentes,
    NTILE(4) OVER (ORDER BY number_times_delayed_payment_loan_30_59_day
s) AS quartil_atrasos,
    NTILE(4) OVER (ORDER BY qtd_emprestimos) AS quartil_emprestimos,
    NTILE(4) OVER (ORDER BY renda_per_capita) AS quartil_renda,
    NTILE(4) OVER (ORDER BY salario) AS quartil_salario,
    NTILE(4) OVER (ORDER BY using_lines_not_secured_personal_assets) AS
quartil_using_lines,
  FROM `projetolab3.bancocaja.caja_unificada`
)

-- Uma união com todos os quartis analisados separadamente
```

```sql
SELECT
  'salario' AS variavel,
  quartil_salario AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_salario

UNION ALL

SELECT
  'renda_per_capita' AS variavel,
  quartil_renda AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_renda

UNION ALL

SELECT
  'debt_ratio' AS variavel,
  quartil_debt_ratio AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_debt_ratio

UNION ALL

SELECT
  'using_lines' AS variavel,
  quartil_using_lines AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_using_lines

UNION ALL
```

```sql
SELECT
  'atrasos_30_59_dias' AS variavel,
  quartil_atrasos AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_atrasos

UNION ALL

SELECT
  'idade' AS variavel,
  quartil_idade AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_idade

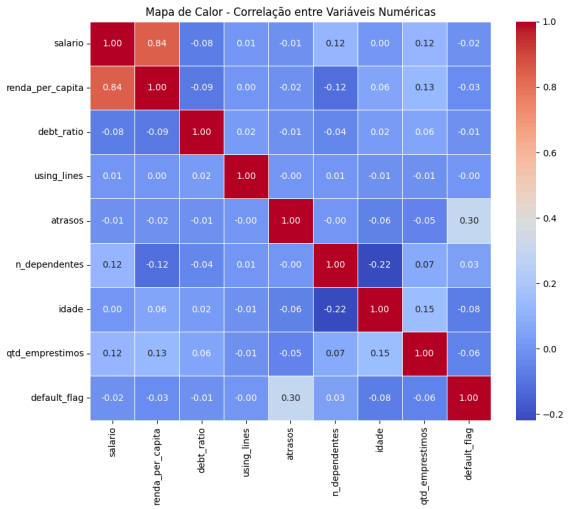
UNION ALL

SELECT
  'n_dependentes' AS variavel,
  quartil_dependentes AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_dependentes

UNION ALL

SELECT
  'qtd_emprestismos' AS variavel,
  quartil_emprestimos AS grupo,
  COUNT(*) AS qtd_clientes,
  SUM(default_flag) AS inadimplentes,
  ROUND(SUM(default_flag) / COUNT(*) * 100, 2) AS pct_inadimplentes
FROM base
GROUP BY quartil_emprestimos
```

https://drive.google.com/file/d/17h_m_K0gH8MKAd83Yyy367YwRoiCJwN1/view?usp=sharing



💬 **RESULTADOS / INSIGHTS:**

Quartis + Percentual de Inadimplência

- `atrasos_30_59_dias`: Quartil 4 concentra **7,11%** de inadimplência — disparado o maior valor da base. Isso valida o uso dessa variável para prever risco.
- `debt_ratio`: Quartil 4 (6,92%) e Quartil 3 (2,24%) possuem inadimplência mais elevada, indicando que altos valores de relação dívida/renda estão ligados ao risco de inadimplência.
- `salário`: Quartil 1 (salários mais baixos) tem 2,26% de inadimplência, enquanto o Quartil 4 tem apenas 0,01%. Forte relação inversa entre salário e risco.
- `using_lines`: Quartil 4 apresenta 3,42% de inadimplência, sugerindo que clientes utilizando mais do seu limite de crédito são mais arriscados.
- `idade` e `n_dependentes`: Todos os quartis têm percentuais muito próximos (~1,1%–1,8%), indicando menor poder de diferenciação para prever inadimplência.
- `qtd_emprestimos`: Quartil 1 (menos empréstimos) tem inadimplência de 1,91%, maior que os demais. Isso sugere que mesmo quem pega poucos empréstimos pode representar risco — talvez por serem novos ou mal avaliados.

Correlação entre Variáveis Numéricas

O mapa de calor mostra correlações fracas entre as variáveis, com destaque para:

- `salario` **x** `renda_per_capita`: Correlação alta (0.84), como esperado, já que ambas envolvem renda.
- `atrasos` **x** `default_flag`: Única correlação **moderada positiva (0.30)** — o que reforça novamente o uso dos atrasos na previsão.

- Demais variáveis têm correlação fraca ou inexistente com `default_flag`, o que reforça a necessidade de **análises segmentadas** por grupos de risco.

▼ MARCO 03: RISCO RELATIVO + SEGMENTAÇÃO + MATRIZ DE CONFUSÃO

1. **DECIDIR CATEGORIAS DE RISCO + APLICAR RISCO RELATIVO:**

♦ **DECIDI SEGUIR A ANÁLISE DE RISCO COM 07 CATEGORIAS DE RISCO:**

1. `salario`
2. `idade`
3. `debt_ratio`
4. `n_dependentes`
5. `emprestimos`
6. `using lines not secured personal assets`
7. `number times delayed payment loan 30 59 days`

♦ **AQUI VAMOS DIVIDIR EM 🔲CASO 01 E ⬛CASO 02 :**

Para avaliar a relação entre a variável `debt_ratio` e a inadimplência, foram aplicadas **duas abordagens distintas** de segmentação da base com o objetivo de comparar os grupos de risco:

🔲CASO 01:

A base foi segmentada em **quartis regulares**, usando a função `NTILE(4)` no `BigQuery`.

- O total de clientes considerados foi de **36.000 registros**, o que gerou **4 grupos iguais com cerca de 9.000 clientes cada**.
- Cada quartil foi então comparado com o restante da base para cálculo do risco relativo.

💬 **RESULTADOS DO RISCO RELATIVO 🔲CASO 01 _ quem se destacou:**

1. `salario` → Q2 (1.94)
2. `idade` → Q1 (2.46)
3. `debt_ratio` → **Q3 (1.26) de 4 grupos.**
4. `n_dependentes` → Q1 (1.51)
5. `emprestimos` → Q1 (2.51)
6. `using lines not secured personal assets` → Q4 (44.65)
7. `number times delayed payment loan 30 59 days` → Q4 (31.15)

💬 **RESULTADOS DO RISCO RELATIVO ⬛CASO 02 _ quem se destacou:**

1. `salario` → Q2 (1.94)
2. `idade` → Q1 (2.46)
3. `debt_ratio` → **Q4 (1.61) de 5 grupos.**
4. `n_dependentes` → Q1 (1.51)
5. `emprestimos` → Q1 (2.51)
6. `using lines not secured personal assets` → Q4 (44.65)
7. `number times delayed payment loan 30 59 days` → Q4 (31.15)

⬛**CASO 02 :**

- Foi identificado, na análise exploratória, que valores de `debt_ratio` **maiores ou iguais a 1.92** representavam discrepantes (baseado no IQR).
- A estratégia adotada foi:
  - Criar um **grupo isolado com os clientes discrepantes (`debt_ratio >= 1.92`)**, totalizando **7.579 registros**.
  - Dividir o restante da base (`debt_ratio < 1.92`) com cerca de **28.420 registros** em **4 grupos (quartis) de ~7.105 clientes cada**.
- Essa abordagem permitiu avaliar melhor o impacto específico dos casos extremos em comparação com os demais perfis da base.

〰️ **CÓDIGOS:**

CÓDIGOS MARCO 03

📎 **SEGMENTAÇÃO E SCORE A PARTIR DO RISCO RELATIVO:**

1. Depois de obter o resultado do risco relativo criei duas views no BigQuery → '`segmentacao_e_risco_01`' e '`segmentacao_e_risco_02`', que são compostas pelo `user_id`, as informações de quartil do mesmo, as "notas" de risco de cada categoria e o `score_risco` (soma das notas de risco) de cada um.
   - Para confirmar se valia a pena observar o comportamento dos dois casos, testei a interseção dos clientes do Q3 e Q4:

▼ ***CÓDIGO DO TESTE***

```
WITH base AS (
  SELECT
    user_id,
    debt_ratio,

    -- Quartis tradicionais (caso 1)
    NTILE(4) OVER (ORDER BY debt_ratio) AS quartil_normal,

    -- Grupos ajustados com corte IQR (caso 2)
    CASE
      WHEN debt_ratio >= 1.92 THEN 5
      ELSE NTILE(4) OVER (ORDER BY debt_ratio)
    END AS grupo_iqr
```

```
  FROM `projetolab3.bancocaja.caja_unificada`
)

SELECT
  COUNT(*) AS qtd_clientes_intersecao
FROM base
WHERE quartil_normal = 3 AND grupo_iqr = 4

--- RESULTADO = 0, OU SEJA, Q3 CASO 01 E Q4 CASO 02 NÃO SÃO FORMADOS PELOS MESMOS CLIENTES.
```

--- RESULTADO = 0, OU SEJA, Q3 CASO 01 E Q4 CASO 02 NÃO SÃO FORMADOS PELOS MESMOS CLIENTES.

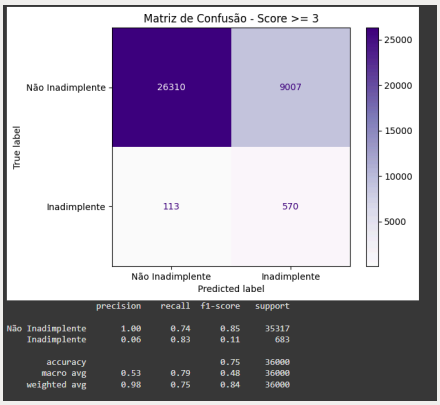
2. **VALIDAR O SCORE COM A MATRIZ DE CONFUSÃO:**

♦ OS TESTES DE MATRIZ DE CONFUSÃO FORAM RODADOS NO https://colab.research.google.com/drive/1Yx-ip8KkN9QLWg-nfWph80RyN7PJzWO3?usp=sharing, REALIZEI DOIS TESTES PARA CADA CASO, COM NOTA DE CORTE ≥3 E ≥4.
✴✴✴**Desequilíbrio da Base**:

- Apenas **683 de 36.000** clientes têm a flag de inadimplência ativa, ou seja, **menos de 2% da base**.
- Esse desequilíbrio influencia a avaliação dos modelos: um modelo pode parecer bom só por prever "não inadimplente" para quase todo mundo.

✴✴✴Por isso, escolhi que olhar para **recall e precisão dos inadimplentes** é mais relevante que a acurácia geral, nesse caso!✴✴✴

💬 RESULTADO MATRIZ DE CONFUSÃO 🔲CASO 01 _ ≥3:

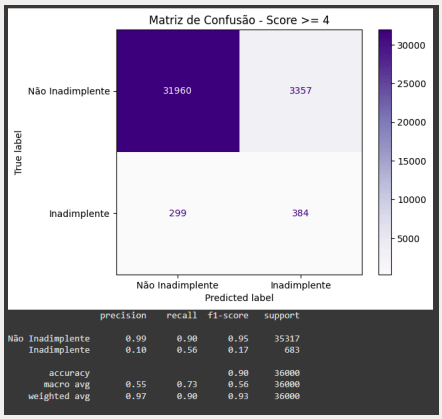


	precision	recall	f1-score	support
Não Inadimplente	1.00	0.74	0.85	35317
Inadimplente	0.06	0.83	0.11	683
accuracy			0.75	36000
macro avg	0.53	0.79	0.48	36000
weighted avg	0.98	0.75	0.84	36000

1. **Desempenho do Score ≥ 3:**
    - **Previsão de Inadimplentes (positivos verdadeiros)**: 570
    - **Falsos negativos (inadimplentes não previstos)**: 113
    - **Maior sensibilidade/recall**: essa configuração capturou melhor os inadimplentes (83% dos 683 expostos), o que é importante quando o objetivo é **minimizar risco e evitar concessões ruins**.
    - **Custo**: aumentou o número de falsos positivos (9.007), ou seja, muitos bons pagadores foram classificados como maus — o que pode impactar negativamente na concessão de crédito a bons clientes.

💬 RESULTADO MATRIZ DE CONFUSÃO ⬛CASO 02 _ ≥3:

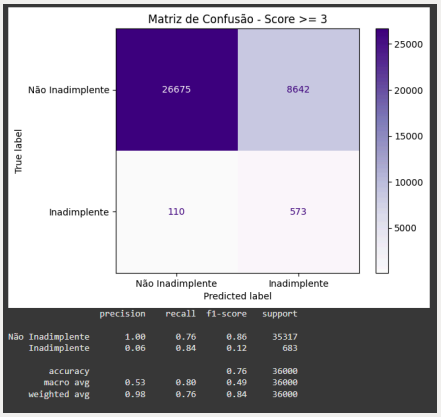
💬 RESULTADO MATRIZ DE CONFUSÃO 🔲CASO 01 _ ≥4:



	precision	recall	f1-score	support
Não Inadimplente	0.99	0.90	0.95	35317
Inadimplente	0.10	0.56	0.17	683
accuracy			0.90	36000
macro avg	0.55	0.73	0.56	36000
weighted avg	0.97	0.90	0.93	36000

2. **Desempenho do Score ≥ 4:**
    - **Previsão de Inadimplentes (positivos verdadeiros)**: 384
    - **Falsos negativos**: 299 inadimplentes não detectados — ou seja, **maior risco de inadimplência não prevista**.
    - **Maior precisão (menos falsos positivos)**: apenas 3.357 bons pagadores foram classificados erroneamente como inadimplentes.
    - Esse corte privilegia **preservar relações com bons clientes**, com risco de **deixar inadimplentes passarem**.

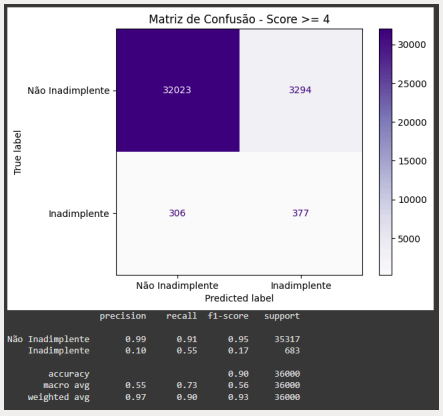
💬 RESULTADO MATRIZ DE CONFUSÃO ⬛CASO 02 _ ≥4:



	precision	recall	f1-score	support
Não Inadimplente	1.00	0.76	0.86	35317
Inadimplente	0.06	0.84	0.12	683
accuracy			0.76	36000
macro avg	0.53	0.80	0.49	36000
weighted avg	0.98	0.76	0.84	36000

1. Desempenho do Score ≥3:

- **Previsão de Inadimplentes (positivos verdadeiros):** 573
- **Falsos negativos (inadimplentes não previstos):** 110
- **Maior sensibilidade/recall:** essa configuração capturou melhor os inadimplentes (84% dos 683 expostos), o que é importante quando o objetivo é minimizar risco e evitar concessões ruins.
- **Custo:** aumentou o número de falsos positivos (8.642), ou seja, muitos bons pagadores foram classificados como maus — o que pode impactar negativamente na concessão de crédito a bons clientes.



	precision	recall	f1-score	support
Não Inadimplente	0.99	0.91	0.95	35317
Inadimplente	0.10	0.55	0.17	683
accuracy			0.90	36000
macro avg	0.55	0.73	0.56	36000
weighted avg	0.97	0.90	0.93	36000

2. **Desempenho do Score ≥ 4:**

- **Previsão de Inadimplentes (positivos verdadeiros):** 377
- **Falsos negativos:** 306 inadimplentes não detectados — ou seja, maior risco de inadimplência não prevista.
- **Maior precisão (menos falsos positivos):** apenas 3.294 bons pagadores foram classificados erroneamente como inadimplentes.
- **Esse corte privilegia preservar relações com bons clientes,** com risco de deixar inadimplentes passarem despercebidos.

https://drive.google.com/file/d/1yRsslme0xZvJ_7XjRuKnhOt90y45IF-t/view?usp=sharing

▼ ✳️ INSIGHTS E DIRECIONAMENTOS:

📎 **CONCLUSÕES GERAIS:**

MODELO DE PREVISÃO:

Na etapa de validação da pontuação de risco com matriz de confusão, foram testadas diferentes notas de corte para verificar o desempenho da classificação entre inadimplentes e não inadimplentes. Considerando o desbalanceamento da base (apenas 683 clientes inadimplentes entre 36.000), foi possível observar que:

- **Score ≥ 3 CASO 02** apresentou o melhor equilíbrio entre identificar inadimplentes e evitar muitos falsos positivos.
  - **Recall para inadimplentes** foi de **84%**, o maior entre todos os testes, ou seja, conseguimos identificar 84% dos inadimplentes reais.
  - Mesmo com uma **baixa precisão (6%)**, isso é esperado, pois a base tem poucos inadimplentes e muitos clientes com características semelhantes.
  - **F1-score** dos inadimplentes foi **0.12**, superior ao score 4 e com macro média melhor (0.49).
  - É o cenário mais seguro caso o objetivo principal seja **minimizar inadimplência**.

✴️Dado que o objetivo principal do projeto é ajudar o banco a evitar inadimplência, **o Score ≥ 3 do CASO 02 é o mais indicado**. Ele apresenta maior capacidade de capturar clientes inadimplentes (mesmo que com mais falsos positivos), o que é aceitável em cenários de crédito onde o custo de conceder a clientes inadimplentes é muito mais alto do que o de rejeitar um cliente adimplente por excesso de cautela.

📎 **INSIGHTS GERAIS SOBRE A BASE DE CLIENTES:**

A maioria dos clientes está na faixa de **31 a 40 anos**, que também concentrou a **maior proporção de inadimplentes**, sugerindo um possível ponto de atenção.

- **Mais de 70% dos clientes possuem até 3 salários mínimos**, o que indica que o banco atende majoritariamente a **pessoas de baixa renda.**
- A **mediana de idade é 52 anos**, com **renda per capita baixa (mediana: R$ 2.553)**, reforçando o perfil de um público mais maduro e com compromissos financeiros ativos.

Inadimplência

- A **variável com maior correlação com inadimplência** foi `number_times_delayed_payment_loan_30_59_days` (atrasos passados), com correlação moderada de **0.30**, confirmando que o **histórico de atraso é um dos principais preditores** de novo default.
- A maior parte dos inadimplentes **possui salário** (ou seja, **não ter salário declarado não significa automaticamente risco maior**).

- Clientes com **menor escolaridade sobre as variáveis financeiras** (baixo salário, dependentes, muitos empréstimos) tendem a estar nos **grupos com maior risco relativo**, embora a correlação entre variáveis seja, no geral, fraca.
- A variável `debt_ratio` mostrou um comportamento importante:
  - A maioria da base tem valores baixos (até 1.5),
  - Mas um grupo **discrepante** com valores acima de **1.92** apresentou **risco relativo mais alto** e comportamento diferenciado — levando à criação de um grupo à parte.

Grupos de Risco Relevantes Identificados

- **Faixa etária mais jovem (quartil 1)** apresentou maior risco relativo, sugerindo que clientes mais novos estão mais propensos a inadimplência.
- **Clientes com mais empréstimos (quartil 1 de `qtd_emprestimos`)** também mostraram risco mais elevado — talvez pela alta recorrência ou possível sobrecarga financeira.
- A **renda per capita e o número de dependentes** tiveram impacto mais discreto, mas clientes com **mais dependentes e baixa renda per capita** ainda exigem atenção em segmentações futuras.
- Os grupos com **uso extremo de linhas de crédito** (`using_lines`) apresentaram distribuição desigual, com muitos valores baixos, mas uma **cauda de casos com uso alto**, também potencialmente ligados a risco.

🛠️ **DIRECIONAMENTOS_ futuro:**
1. Investigar o uso dos dados discrepantes como variáveis auxiliares ou novos grupos de risco

- O tratamento especial dado ao grupo extremo de `debt_ratio` (≥ 1.92) demonstrou impacto significativo na performance do modelo. Isso indica que outros **valores extremos** — como os de `using_lines_not_secured_personal_assets` e `salário` — **podem carregar padrões relevantes de risco.**
- ➤ **Próximo passo:** isolar e testar o impacto de clientes com valores muito altos em `using_lines`, criando grupos específicos como foi feito com `debt_ratio`, e medir o risco relativo desses grupos.

2. Corrigir o desbalanceamento da variável target `default_flag`

- O modelo enfrenta grande desequilíbrio: apenas **1,9% dos clientes são inadimplentes (683 de 36.000)**.
- Isso afeta diretamente a **capacidade do modelo de aprender padrões reais de inadimplência**, gerando alta taxa de falsos positivos ou falsos negativos, dependendo do corte.

- ➤ **Próximo passo:** aplicar técnicas de **rebalanço da base.**

3. Enriquecer a base de dados com mais informações do cliente

- A base atual é limitada a poucas variáveis numéricas e não possui dados qualitativos importantes como:
  - Tipo de trabalho ou setor,
  - Escolaridade,
  - Localidade,
  - Histórico bancário,
  - Garantias (colaterais) dos empréstimos.
- ➤ **Próximo passo:** coletar ou cruzar com novas fontes de dados internos (CRM, transacional, histórico de crédito) para enriquecer o modelo e permitir classificações mais precisas.

4. Aprofundar a compreensão dos indicadores `debt_ratio` e `using_lines`

- Ainda existem **dúvidas sobre a composição dessas variáveis.** São indicadores compostos e o significado de seus valores altos ou baixos pode variar conforme o perfil do cliente.
- ➤ **Próximo passo:**
  - Entender como o banco calcula esses indicadores.
  - Verificar se são agregações de outras dívidas, se incluem garantias ou apenas consumo de linhas de crédito rotativo.
  - Avaliar se essas variáveis não estão sofrendo de **multicolinearidade** ou distorções.

5. Explorar a relação entre tipos de empréstimos e inadimplência

- A variável `qtd_emprestimos` foi usada, mas o **tipo** dos empréstimos pode revelar padrões valiosos.
- Por exemplo: other vs. real estate. Alguns produtos têm risco de inadimplência muito diferente.
- ➤ **Próximo passo:**
  - Mapear os tipos de empréstimo na base original (`tipo_padronizado`, por exemplo).
  - Calcular inadimplência por tipo.
  - Incluir como variável categórica no modelo ou nas regras de pontuação.
